艾歆 作品集

大数据管理与应用专业 2026 届

技术栈

Python | R | SQL | Tableau | SPSS | Kettle | Excel

机器学习 | 统计分析 | 数据可视化 | ETL

联系方式

邮箱：ai1200805@163.com

电话：185-4522-2254

GitHub：github.com/vanessa1-yu

项目一：电子商务用户行为分析及服务推荐

时间：2024.09-2024.10

技术：Python、随机森林、SVM、Matplotlib

类型：机器学习项目

项目目标

构建用户价值预测模型，识别高价值用户，设计差异化推荐策略。

核心成果

模型准确率 **94%**

发现核心特征：历史消费金额、用户活跃度、购买次数

输出差异化推荐策略

关键图表

```
SVM分析结果:

分类报告:
              precision    recall  f1-score   support

        中价值       0.81      0.87      0.84        82
        低价值       0.90      0.86      0.88        66
        高价值       0.90      0.85      0.87        52

    accuracy                           0.86       200
   macro avg       0.87      0.86      0.86       200
weighted avg       0.86      0.86      0.86       200


=== 电子商务用户行为分析报告 ===

1. 用户基础统计:
                 年龄         浏览次数         购买次数       历史消费金额
count  1000.00000  1000.00000  1000.000000  1000.000000
mean     43.81900    48.83500    14.417000  4978.855929
std      14.99103    29.13377     8.552676  2883.893943
min      18.00000     1.00000     0.000000     2.270382
25%      31.00000    22.00000     7.000000  2575.938032
50%      44.00000    48.00000    14.000000  4823.092877
75%      56.00000    74.00000    22.000000  7486.973192
max      69.00000    99.00000    29.000000  9987.929358

2. 用户价值分布:
低价值    334
中价值    333
高价值    333
Name: 用户价值, dtype: int64

3. 支付方式偏好:
微信支付    261
其他        255
支付宝      244
银行卡      240
Name: 常用支付方式, dtype: int64

4. 设备使用情况:
小程序    276
PC端      252
平板      241
移动端    231
Name: 常用设备, dtype: int64
```

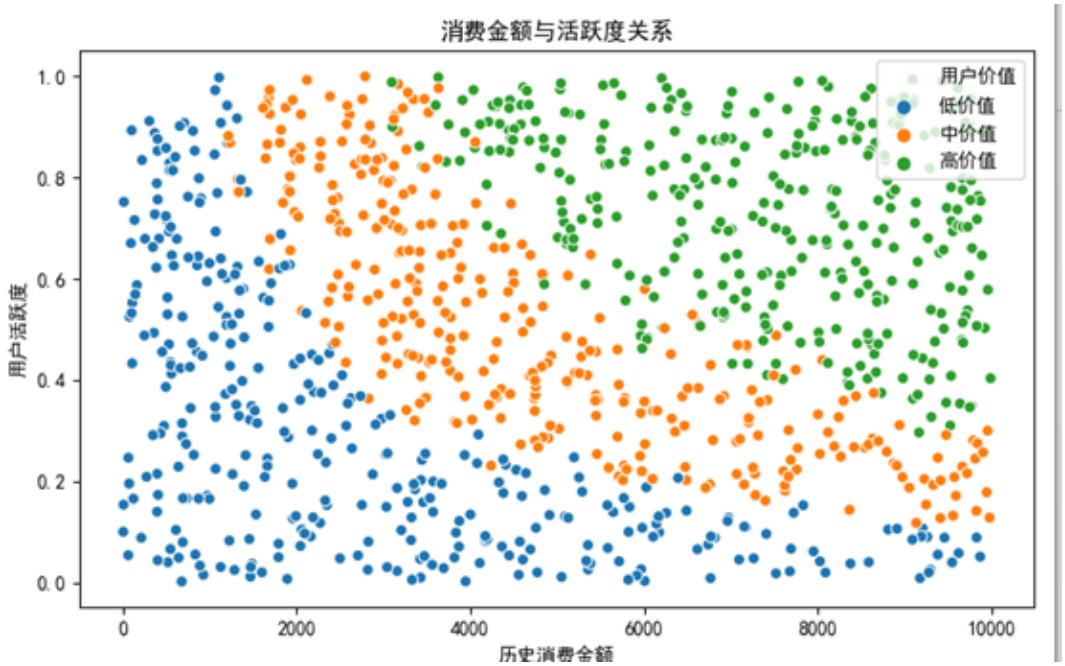
消费金额与活跃度关系
用户价值
低价值
中价值
高价值
用户活跃度
历史消费金额
0.0
0.2
0.4
0.6
0.8
1.0
0
2000
4000
6000
8000
10000

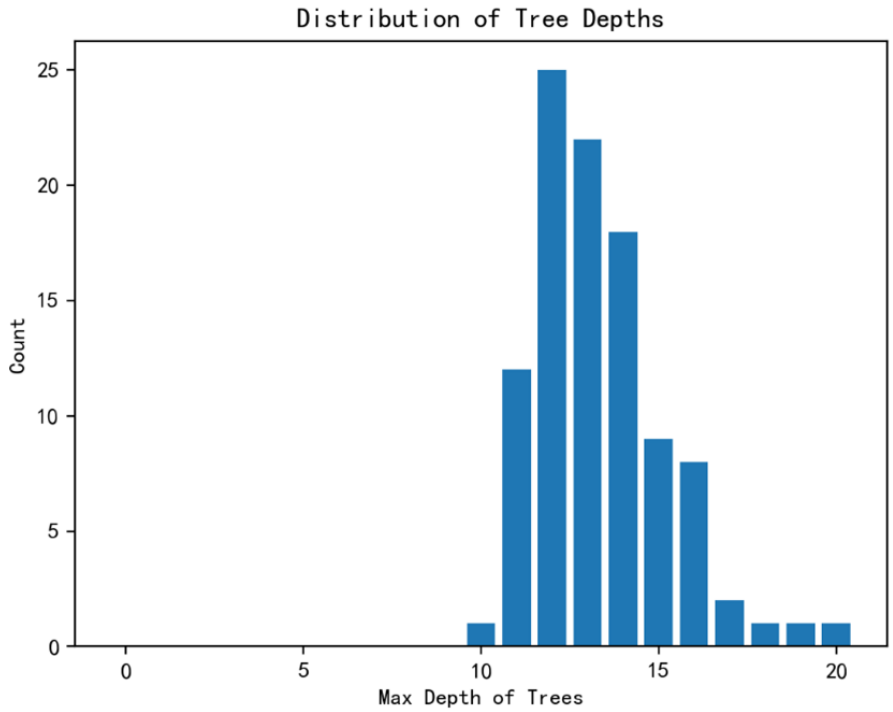
Distribution of Tree Depths
Count
Max Depth of Trees
0
5
10
15
20
25

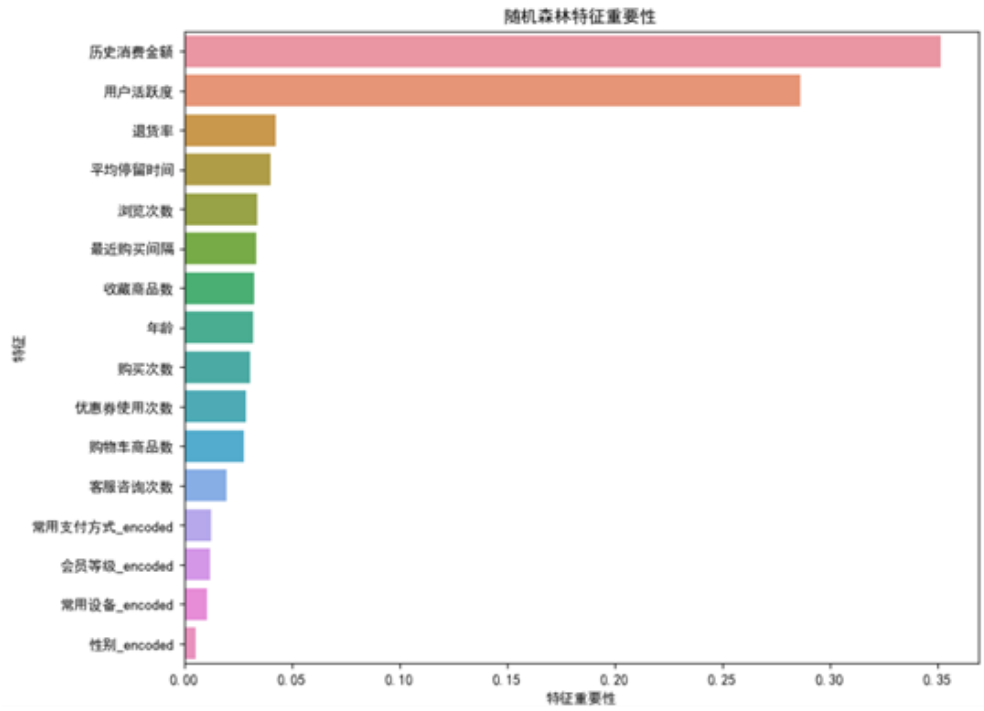

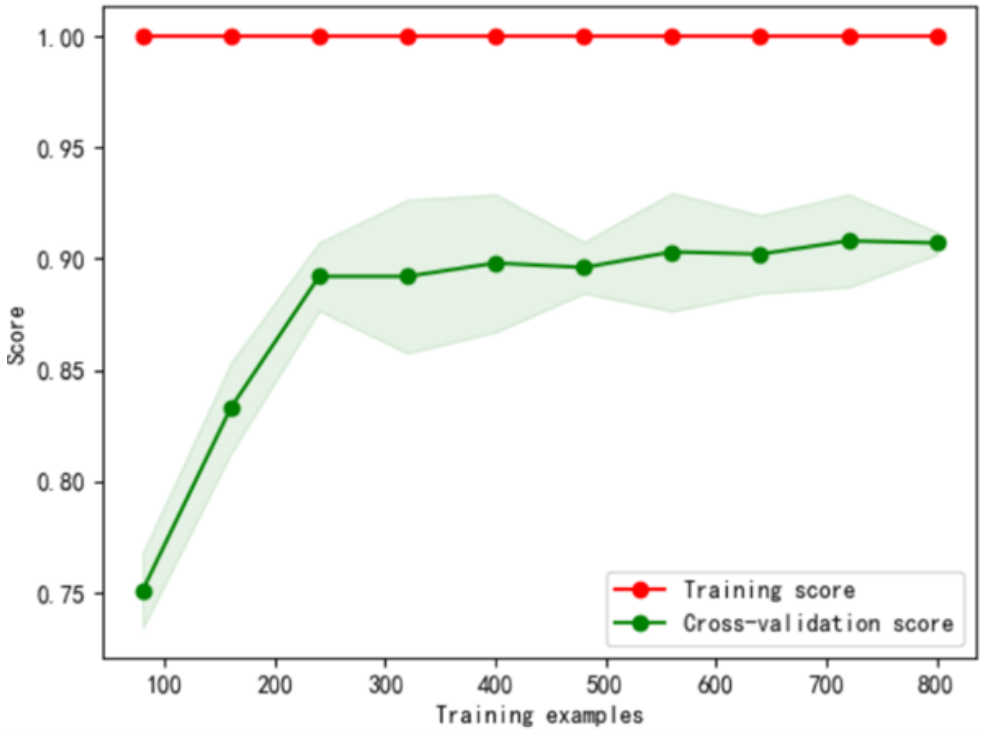

策略输出

用户类型	推荐策略
高价值用户	VIP 专属服务、新品优先购、专属客服
中价值用户	会员升级优惠、个性化商品推荐
低价值用户	优惠券包、限时特价推送

项目二：电动汽车产业财务数据分析

时间：2025.06-2025.07
技术：Python、R、Tableau
类型：数据分析项目
项目目标
通过多维数据分析，揭示电动汽车产业生态规律，为车企产能优化和产业规划提供依据。
数据规模
2 万余条电动汽车数据
时间跨度：2018-2023 年
核心发现

分析维度	关键发现
产地分布	深圳、上海等城市依托电子产业形成产能高地
品牌利润	特斯拉、小鹏依靠技术溢价获利，传统车企利润承压
产销关系	比亚迪产销率 98%+，新势力品牌存在 15%-20%产能过剩
续航需求	不同职业用户对续航需求差异显著

关键图表

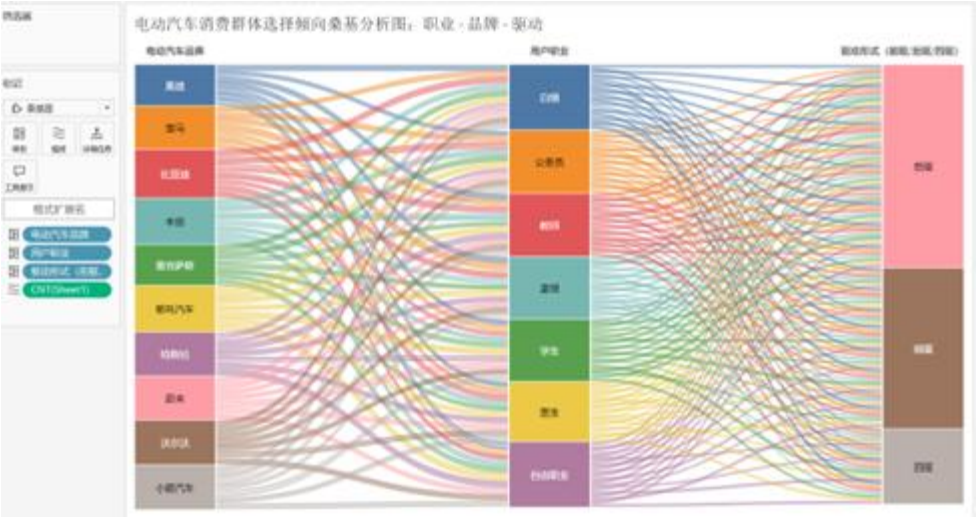

筛选器
标记
动汽车产地 - 厂商销量层级分布

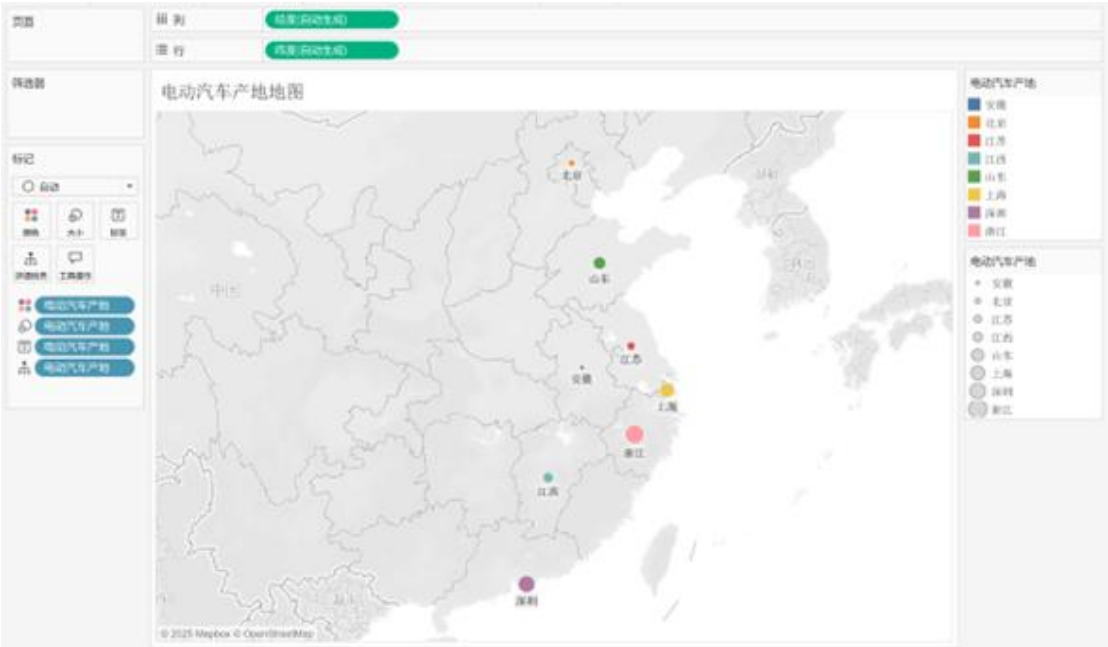
页面
筛选器
标记
电动汽车产地地图
电动汽车产地
© 2025 Mapbox © OpenStreetMap

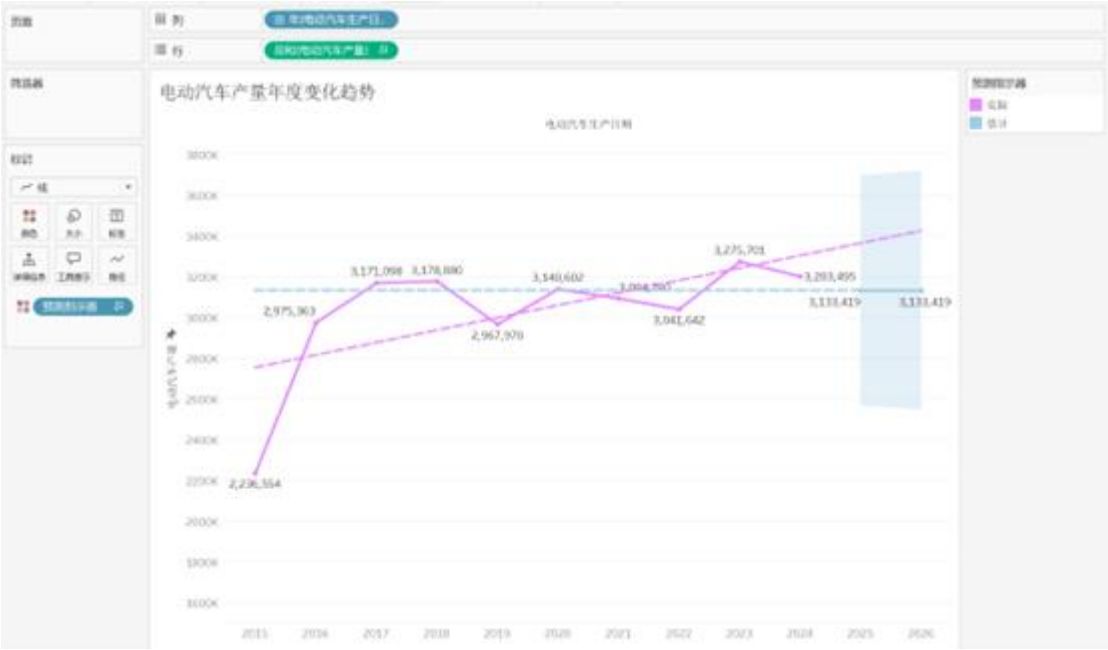
电动汽车产量年度变化趋势
2,236,554
2,975,363
3,171,098
3,178,880
2,967,970
3,140,602
3,041,642
3,275,701
3,203,495
3,131,419
3,131,419

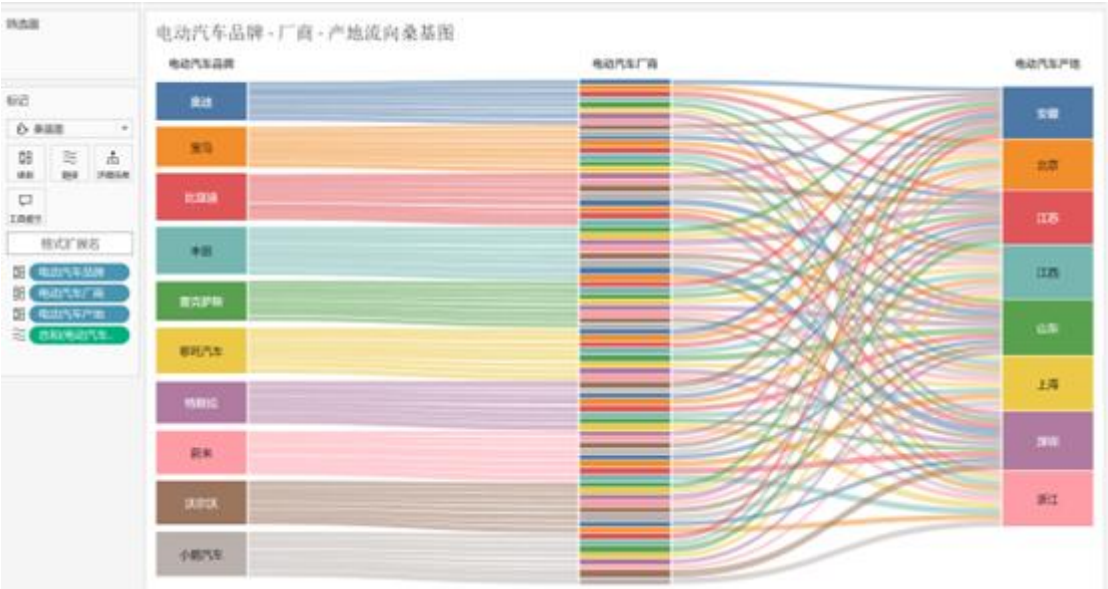
电动汽车品牌 - 厂商 - 产地流向桑基图
电动汽车品牌
电动汽车厂商
电动汽车产地

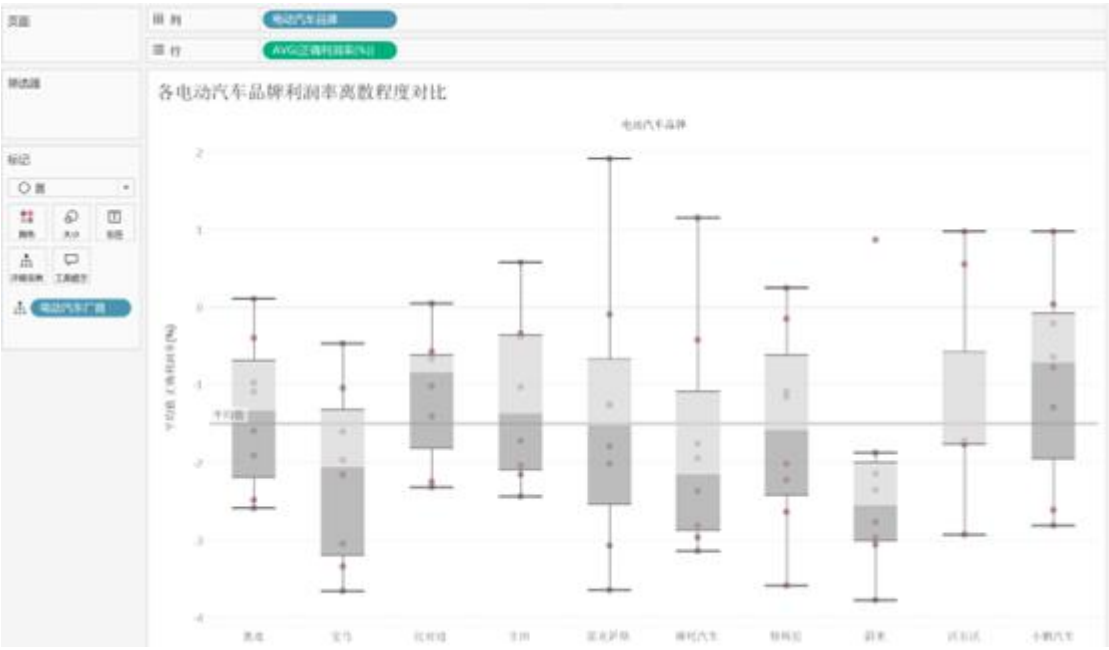
各电动汽车品牌利润率离散程度对比

电动车品牌各地区数量地图

不同职业用户的高/低里程续航表现分布
54,469
52,706
53,677
54,318
50,857
52,424
53,965
33,553
32,167
30,542
29,091
32,307
26,517

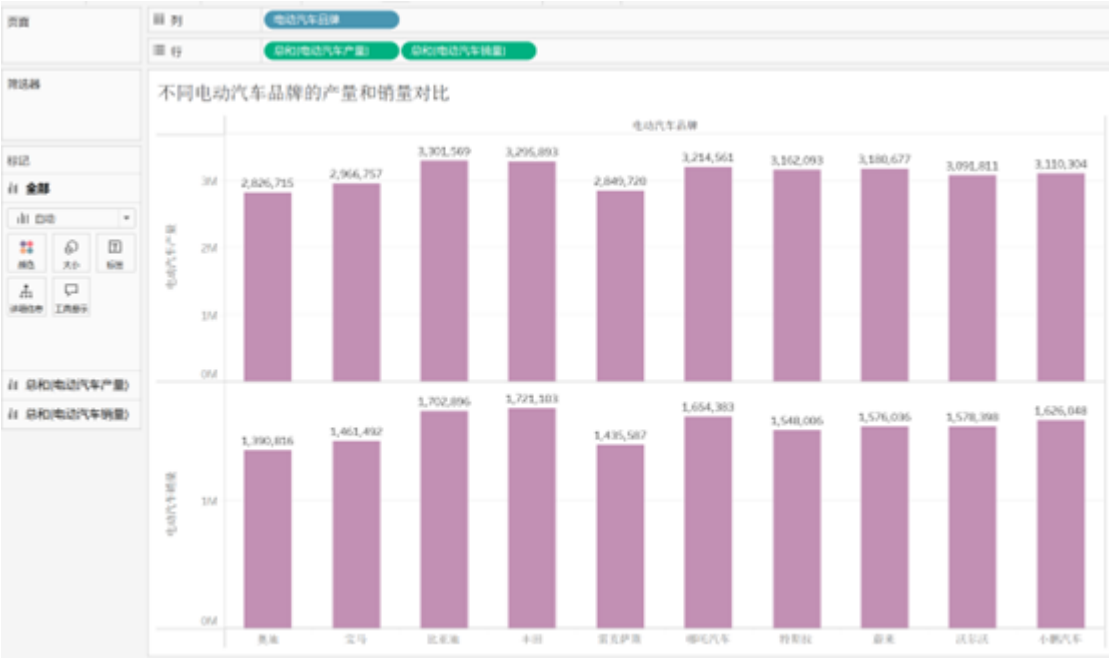
不同电动汽车品牌的产量和销量对比
2,826,715
2,966,757
3,301,569
3,295,893
2,849,720
3,214,561
3,162,093
3,180,677
3,091,811
3,310,304
1,390,816
1,461,492
1,702,896
1,721,103
1,435,587
1,654,383
1,548,006
1,576,036
1,578,398
1,626,048

筛选器
标记
电动汽车品牌市场份额分布
电动汽车品牌
9.296%
9.735%
10.522%
10.548%
9.215%
10.369%
9.946%
9.849%
10.076%
10.044%

项目三：旅游网站用户聚类与回归分析

时间：2024.12-2025.01
技术：R 语言、K-Means 聚类、线性回归、ggplot2
类型：R 项目
项目目标
通过聚类分析和回归分析，识别不同用户群体特征，为精准营销提供依据。
分析方法
聚类分析（K-Means）：
识别出高评论型、高喜欢型等四类用户
线性回归分析：
发现停留时间与浏览量显著正相关
$p < 0.001$，$R^2 = 0.38$
关键图表

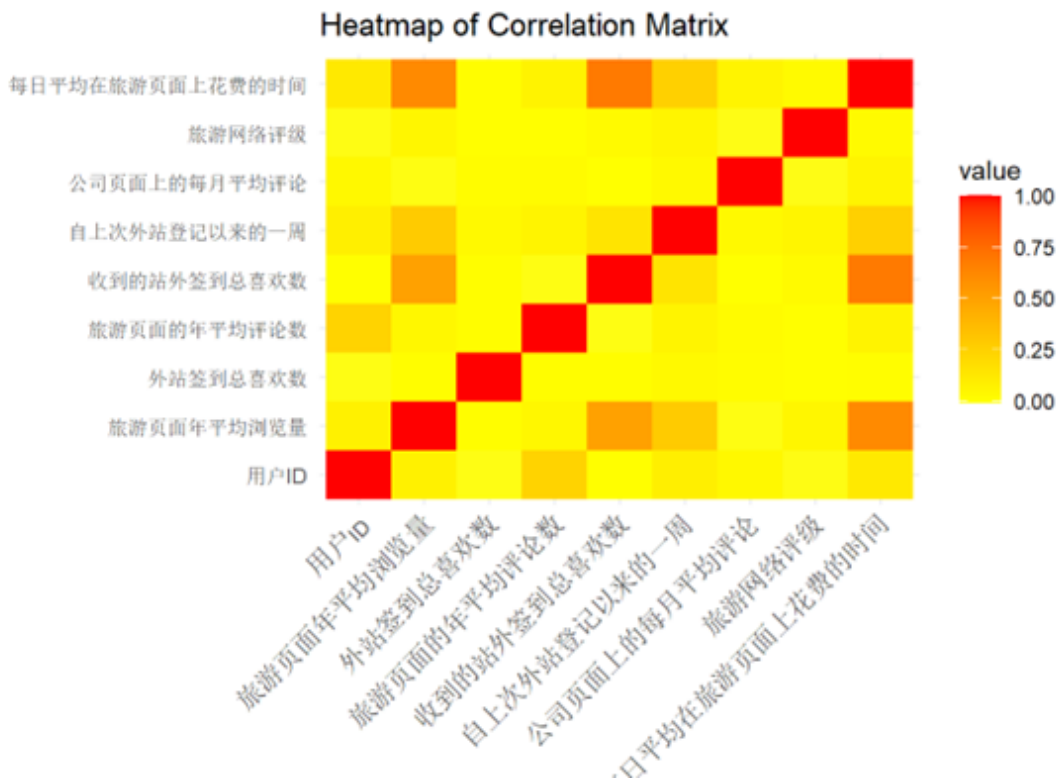

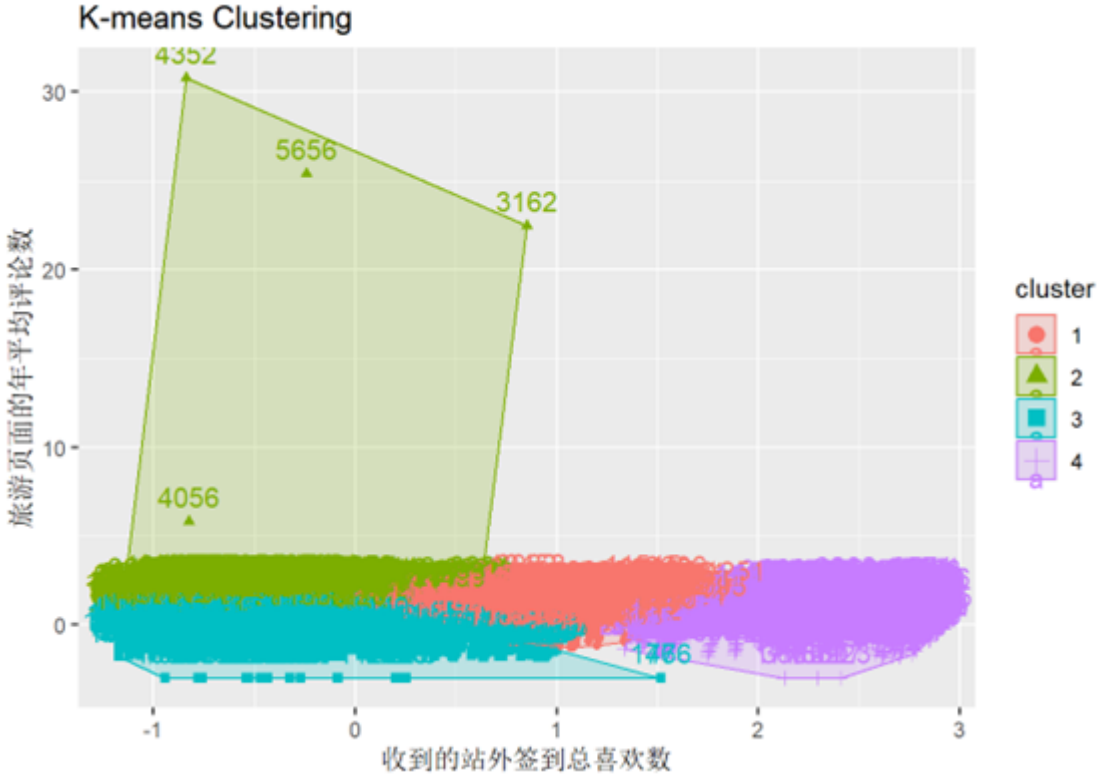
K-means Clustering
4352
5656
3162
4056
1466
30
20
10
0
-1
0
1
2
3
旅游页面的年平均评论数
收到的站外签到总喜欢数
cluster
1
2
3
4

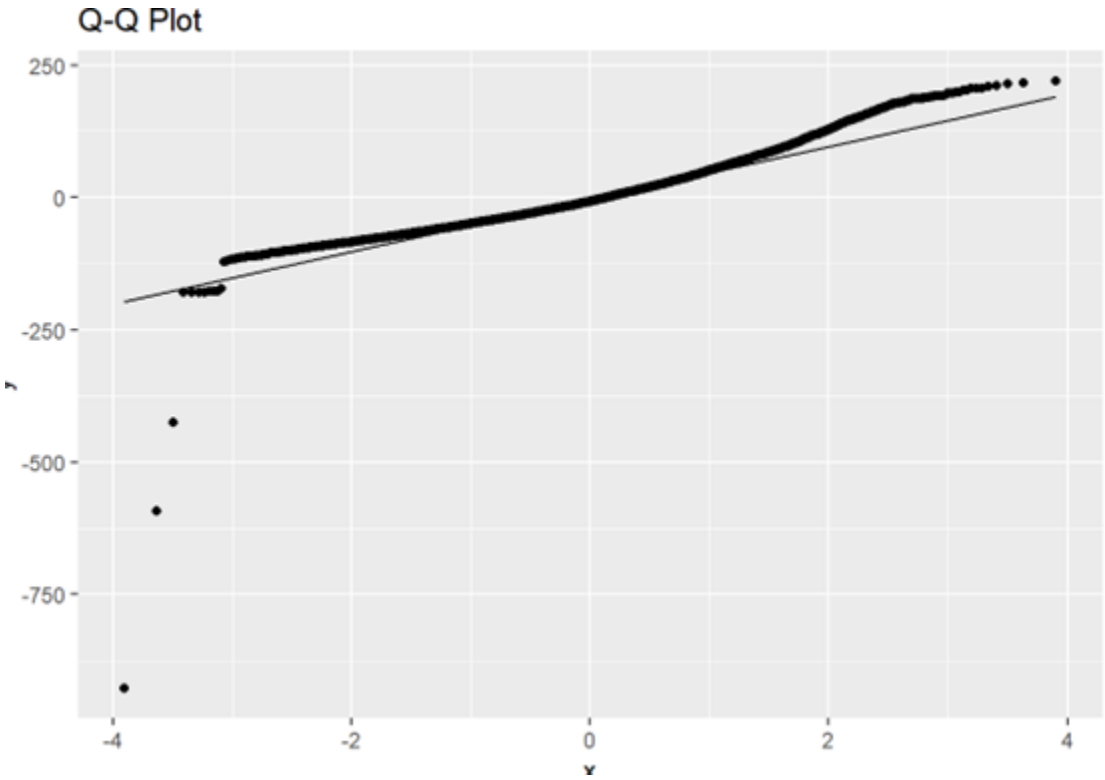
Q-Q Plot
250
0
-250
-500
-750
-4
-2
0
2
4

```
> summary(data3)
     用户ID          使用产品          旅游页面年平均浏览量    首选设备
 Min.   :1000001   Length:10666       Min.   : 35          Length:10666
 1st Qu.:1003347   Class :character   1st Qu.:232          Class :character
 Median :1006428   Mode  :character   Median :271          Mode  :character
 Mean   :1006206                      Mean   :281
 3rd Qu.:1009094                      3rd Qu.:324
 Max.   :1011760                      Max.   :464
 外站签到总喜欢数 年度平均出站登记      家庭成员          首选位置类型
 Min.   :  3570   Length:10666       Length:10666       Length:10666
 1st Qu.: 16335   Class :character   Class :character   Class :character
 Median : 28175   Mode  :character   Mode  :character   Mode  :character
 Mean   : 28173
 3rd Qu.: 40535
 Max.   :152465
 旅游页面的年平均评论数 收到的站外签到总喜欢数 自上次外站登记以来的一周
 Min.   :  3.00         Min.   : 1009          Min.   : 0.000
 1st Qu.: 57.00         1st Qu.: 2951          1st Qu.: 1.000
 Median : 75.00         Median : 4946          Median : 3.000
 Mean   : 75.05         Mean   : 6531          Mean   : 3.205
 3rd Qu.: 93.00         3rd Qu.: 8394          3rd Qu.: 5.000
```

```
> summary(model)

Call:
lm(formula = 旅游页面年平均浏览量 ~ 每日平均在旅游页面上花费的时间,
    data = data3)

Residuals:
    Min      1Q  Median      3Q     Max
-926.13  -37.03   -7.41   29.70  220.51

Coefficients:
                              Estimate Std. Error t value Pr(>|t|)
(Intercept)                   214.9242     0.9682  221.99   <2e-16 ***
每日平均在旅游页面上花费的时间   4.7838     0.0591   80.95   <2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 53.7 on 10664 degrees of freedom
Multiple R-squared:  0.3806,    Adjusted R-squared:  0.3805
F-statistic:  6553 on 1 and 10664 DF,  p-value: < 2.2e-16
```

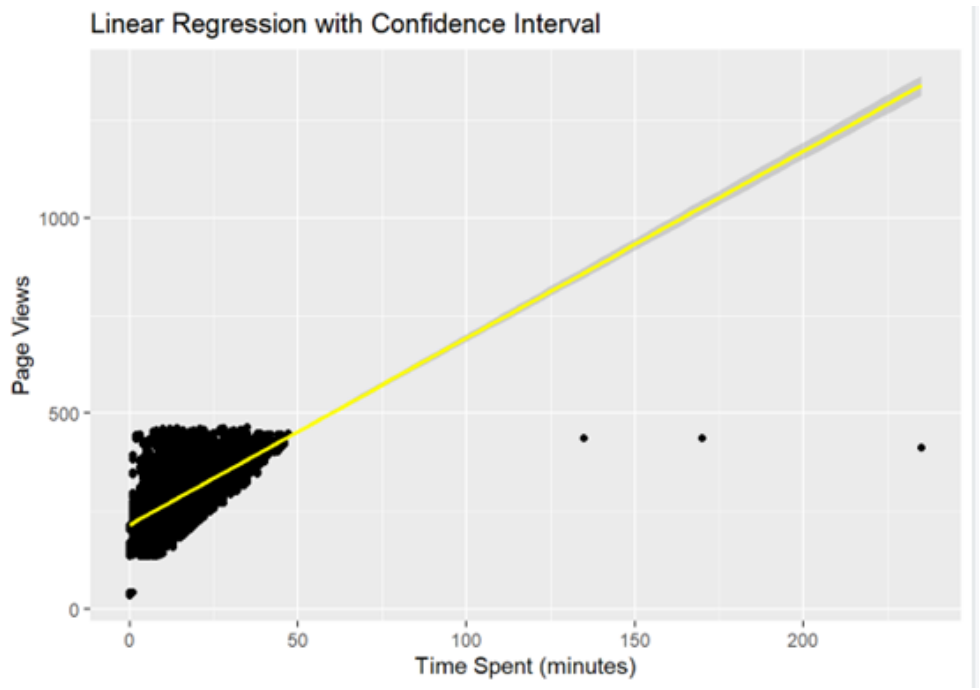
Linear Regression with Confidence Interval
Page Views
1000
500
0
0
50
100
150
200
Time Spent (minutes)

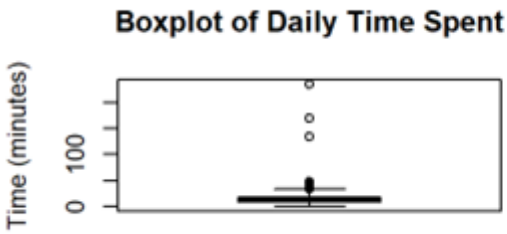
Boxplot of Daily Time Spent
Time (minutes)
0
100

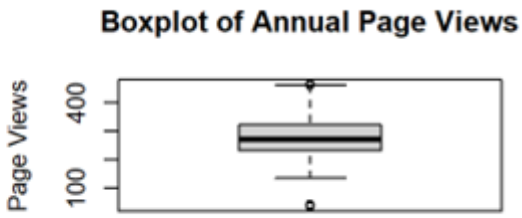
Boxplot of Annual Page Views
Page Views
100
400

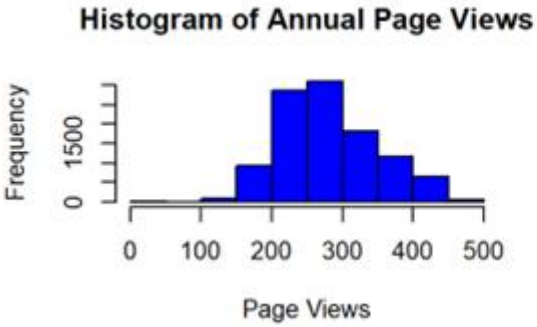
Histogram of Annual Page Views
Frequency
0
1500
0
100
200
300
400
500
Page Views

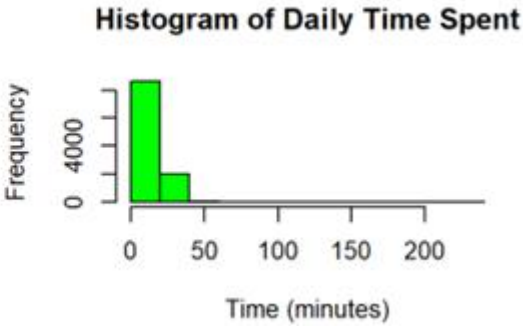
Histogram of Daily Time Spent
Frequency
0
4000
0
50
100
150
200
Time (minutes)

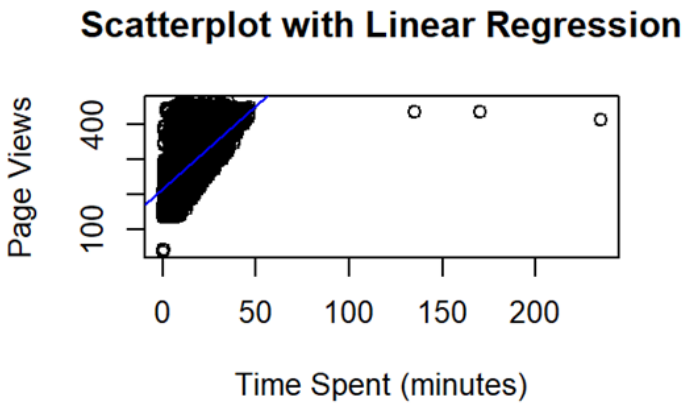
Scatterplot with Linear Regression
Page Views
100
400
0
50
100
150
200
Time Spent (minutes)

项目四：ChatGPT 在大学生中的舆情分析

时间：2024.10-2024.11
技术：Python、SnowNLP、Pyecharts
类型：NLP 项目
项目目标
通过微博数据采集和情感分析，揭示大学生对 AI 的态度和关注焦点。
数据采集
平台：微博
采集量：1686 条博文
情感分析结果

情感类型	数量	占比
消极	1123	**66.6%**
中立	275	16.3%
积极	288	17.1%

高频关键词
AI、大学生、作业、工作、老师、取代
关键图表

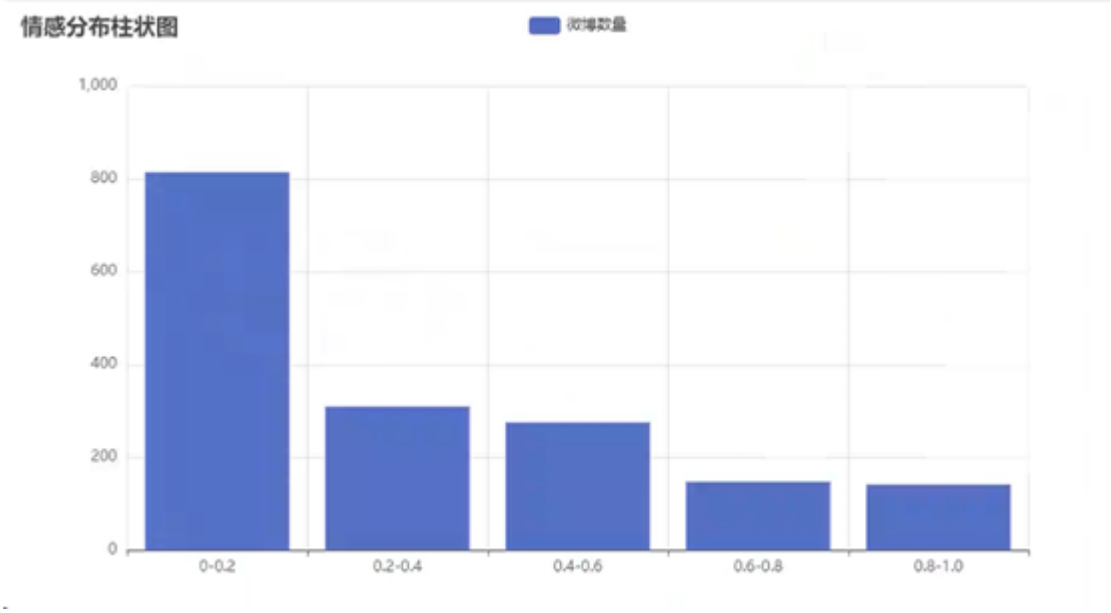

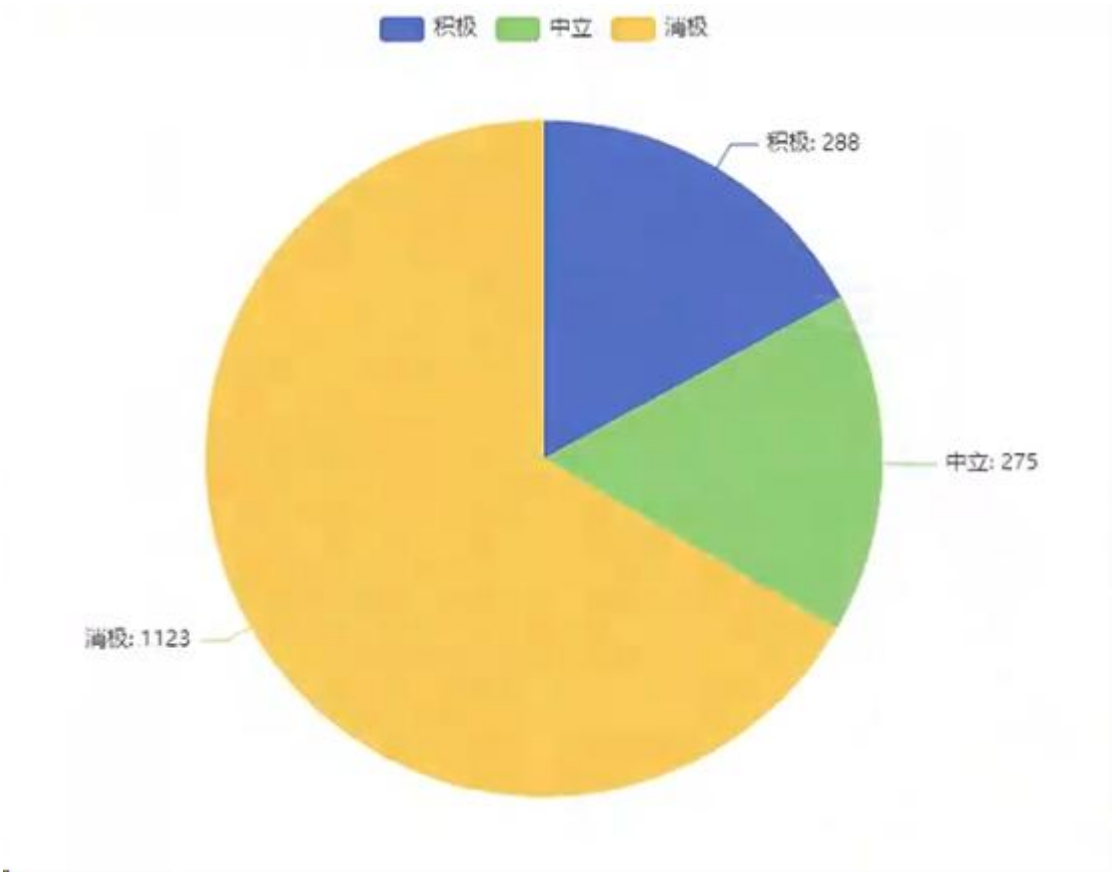
积极
中立
消极
积极: 288
中立: 275
消极: 1123

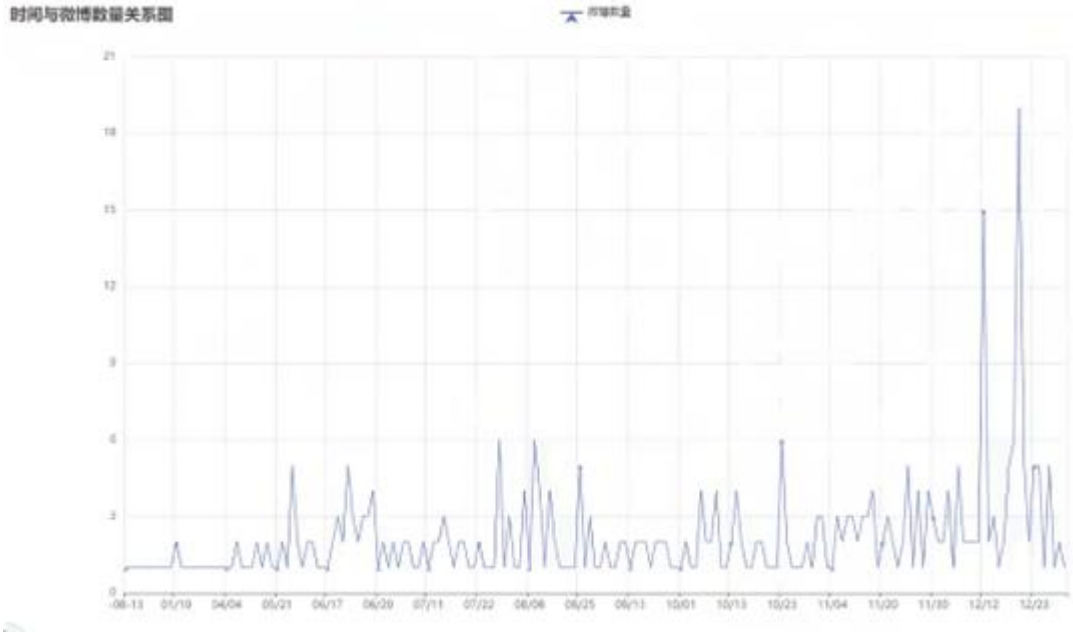
时间与微博数量关系图

主要发现

消极情绪主导，大学生普遍担忧 AI 替代工作、学业压力

讨论焦点围绕“作业”“工作”“取代”等关键词